ANOVA

Dra. Stephanie Hereira Pacheco

CICB, UATx

02-03-2024

Contenido

- Análisis de varianza - ANOVA
- Pruebas paramétricas y supuestos estadísticos
- Supuestos del ANOVA
- ANOVA de una vía

Análisis de varianza - ANOVA

La técnica de análisis de varianza (**ANOVA**) también conocida como análisis factorial y desarrollada por Fisher en 1930

Este análisis constituye la herramienta básica para el estudio del **efecto de una o más variables independientes** (cada uno con dos o más niveles) sobre la media de **una variable continua**.

Análisis de varianza - ANOVA

El análisis de varianza nos permite evaluar el efecto de k variables independientes y su interacción en un experimento.

En el ANOVA las variables independientes se denominan **factores**.

Pero antes de seguir....

- ¿Sabes qué es una variable dependiente e independiente?
- ¿Qué es un factor y cuáles son sus niveles?
- ¿Qué es una variable continua y una variable discreta?
- ¿Qué es una interacción entre factores?

Análisis de varianza - ANOVA

Cuando existe una única variable independiente se denomina **Anova de un factor** (one way anova, en inglés), cuando son dos **Anova de dos vías** y cuando son más de dos, se denomina como **Anova factorial**.

Pruebas paramétricas y supuestos estadísticos

Antes de comenzar, todas las pruebas estadísticas tienen supuestos...

- ¿Ya conocen alguna prueba estadística?
- ¿Qué supuestos tienen estas pruebas?

Pruebas paramétricas

Se conoce como estadística paramétrica a aquella que se basa en el muestreo de una población con una distribución conocida (**normal**) y con parámetros fijos (**media poblacional, varianza o desviación estándar**).

Pruebas paramétricas

VENTAJAS	DESVENTAJAS
- Sensibles a rasgos de los datos recolectados	- Más complicadas de calcular
- Estimaciones probabilísticas más exactas	- Solo se pueden aplicar si se cumplen sus supuestos
- Tienen una mayor eficiencia y poder estadístico	- Los datos que se pueden observar son limitados

Pruebas paramétricas

TIPO	PRUEBA
Comparación de 2 grupos	t de Student/Welch
Comparación de >2 grupos	**Anova**
Correlación de dos variables	Coeficiente de Pearson
Variables cualitativas	Prueba de Z

Pruebas paramétricas y supuestos estadísticos

Los supuestos de las pruebas paramétricas en general son:

- Distribución conocida (**normal**): visual y pruebas numéricas.
- Homocedasticidad: visual y pruebas numéricas.
- Otros: tamaño de la muestra, variables cuantitativas o continuas, outliers, aleatoriedad, independencia de las observaciones, linealidad.

.

Cada tipo de prueba paramétrica tiene sus propios supuestos

Supuestos estadísticos del ANOVA

Los supuestos del ANOVA son:

- **Distribución normal de los residuales:** $\epsilon_{i,j} \sim N(0, \sigma^2)$. Es decir, los errores (residuos) deben distribuirse normalmente con media 0 y varianza constante.
- **Homocedasticidad**: Todos los grupos comparten la misma varianza poblacional σ^2.
- **Aleatoriedad e independencia**
- **Otros**: Mismo número de observaciones por grupos, variable dependiente continua y variable independiente con tres o más grupos o niveles.

Distribución normal: métodos visuales

```
data_normal<- rnorm(200)
hist(data_normal, col='steelblue'
```

```
data_no_normal<- rexp(100, rate=3
hist(data_no_normal, col='red', m
```

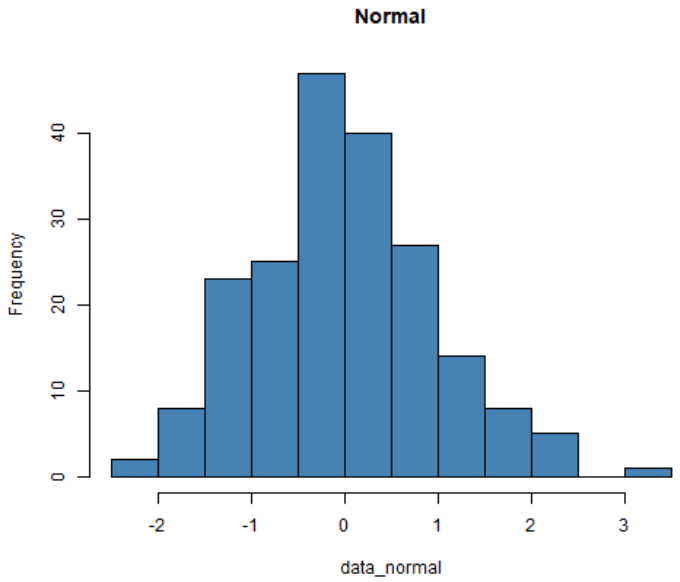

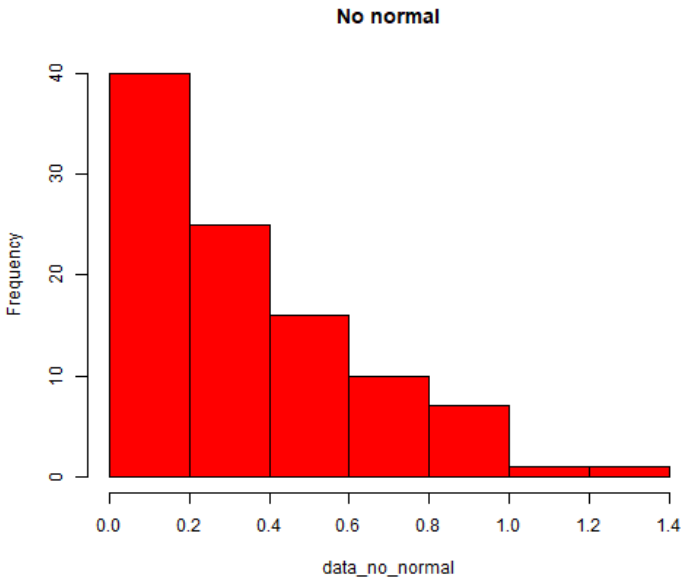

Distribución normal: métodos visuales

```
plot(density(data_normal), main="
```

```
plot(density(data_no_normal), mai
```

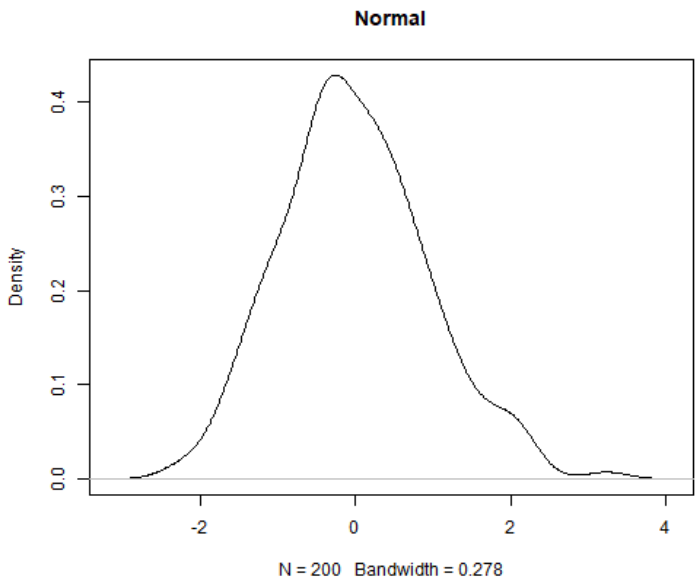

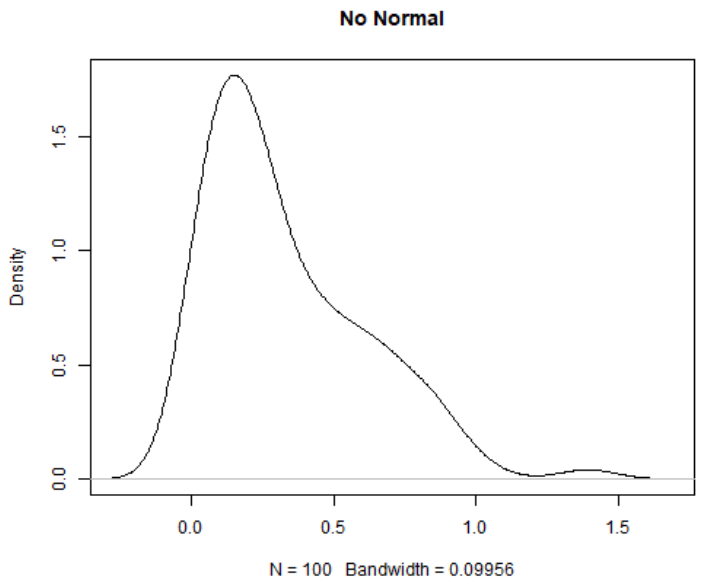

Distribución normal: métodos visuales

```
qqnorm(data_normal)
qqline(data_normal)
```

```
qqnorm(data_no_normal)
qqline(data_no_normal)
```

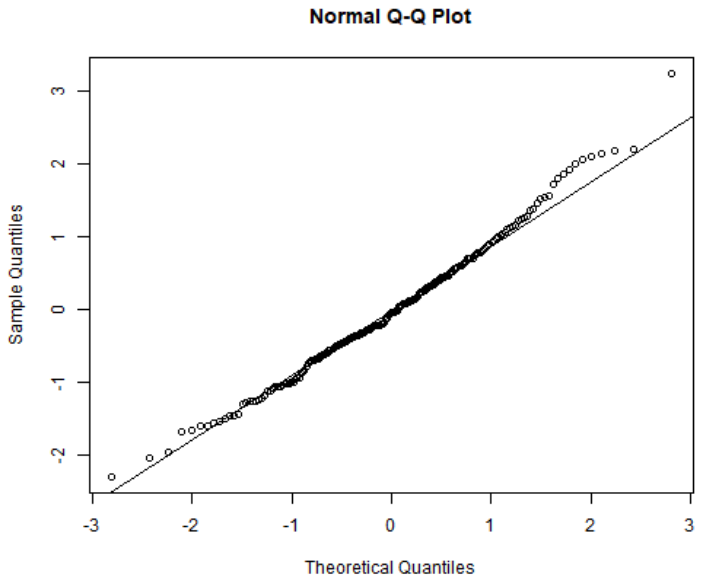

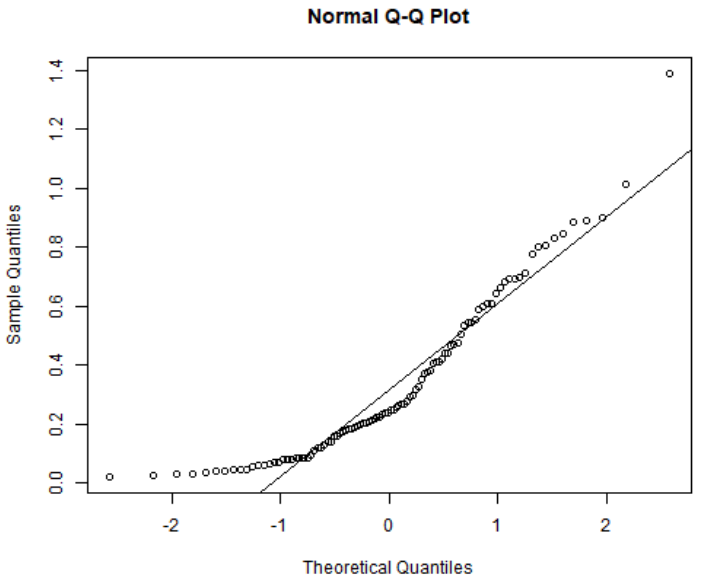

Distribución normal: métodos numéricos

Prueba de Shapiro–Wilk

Hipótesis

H_0: Los datos provienen de una distribución normal

H_1: Los datos no provienen de una distribución normal

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Dónde: $x_{(i)}$ = datos ordenados, $\bar{x}$ = media muestral, a_i = constantes derivadas de la normal teórica, n = tamaño de muestra

Distribución normal: métodos numéricos

Prueba de Kolmogorov–Smirnov

Hipótesis

$$H_0 : F(x) = F_0(x)$$

$$H_1 : F(x) \neq F_0(x)$$

$F(x)$ = distribución acumulada de la muestra

$F_0(x)$ = distribución teórica

$$D = \sup_x |F_n(x) - F_0(x)|$$

Dónde: $F_n(x)$ es la función empírica, $F_0(x)$ es la función teórica y supp la mayor diferencia teórica.

Distribución normal: métodos numéricos

```r
shapiro.test(data_normal)
```

```
##
##     Shapiro-Wilk normality test
##
## data:  data_normal
## W = 0.99076, p-value = 0.2298
```

```r
shapiro.test(data_no_normal)
```

```
##
##     Shapiro-Wilk normality test
##
## data:  data_no_normal
## W = 0.89131, p-value = 5.641e-07
```

```r
ks.test(data_normal, "pnorm")
```

```
##
##     Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  data_normal
## D = 0.053155, p-value = 0.6243
## alternative hypothesis: two-sided
```

```r
ks.test(data_no_normal, "pnorm")
```

```
##
##     Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  data_no_normal
## D = 0.50783, p-value < 2.2e-16
## alternative hypothesis: two-sided
```

Probando heterocedasticidad

- Métodos visuales = Pruebas estadísticas de comparación y modelos lineales

```
data("ToothGrowth")
boxplot(len ~ supp, data=ToothGro
```

```
data("iris")
boxplot(Petal.Width ~ Species, da
```

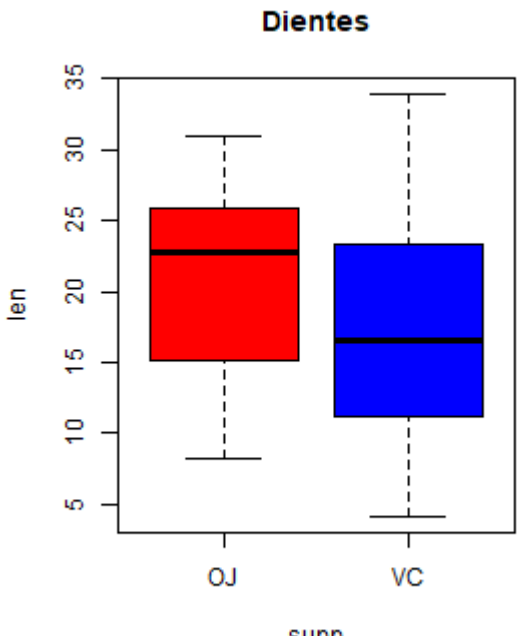

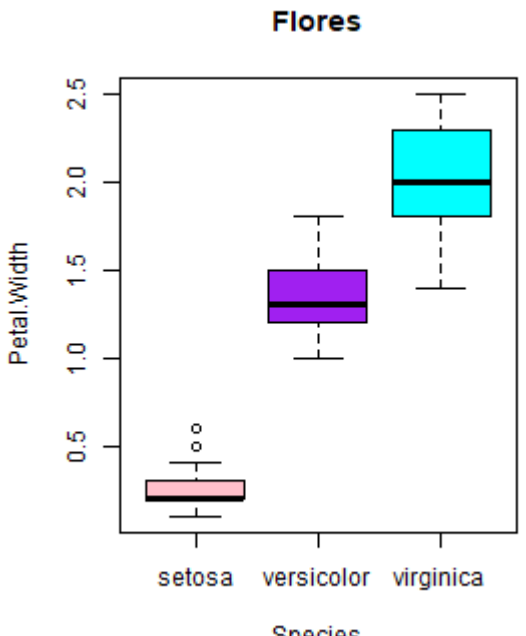

Probando heterocedasticidad

```
aggregate(len ~ supp, data = Toot
```

```
##   supp      len
## 1   OJ 43.63344
## 2   VC 68.32723
```

Ratio

```
68.32 /  43.63
```

```
## [1] 1.565895
```

```
aggregate(Petal.Width ~ Species,
```

```
##      Species Petal.Width
## 1     setosa  0.01110612
## 2 versicolor  0.03910612
## 3  virginica  0.07543265
```

Ratio

```
r1<-0.03910612 / 0.01110612 #vers
r2<-0.07543265 / 0.01110612 #virg
r3<-0.07543264 / 0.03910612 #virg
cbind(r1,r2,r3)
```

```
##             r1       r2       r3
## [1,] 3.521132 6.791989 1.928922
```

Probando heterocedasticidad

```
m1<-lm(len ~ supp, data=ToothGrow
par(mfrow = c(1, 2))
plot(m1, which=c(1,3))
```

```
m2<-lm(Petal.Width ~ Species, dat
par(mfrow = c(1, 2))
plot(m2, which=c(1,3))
```

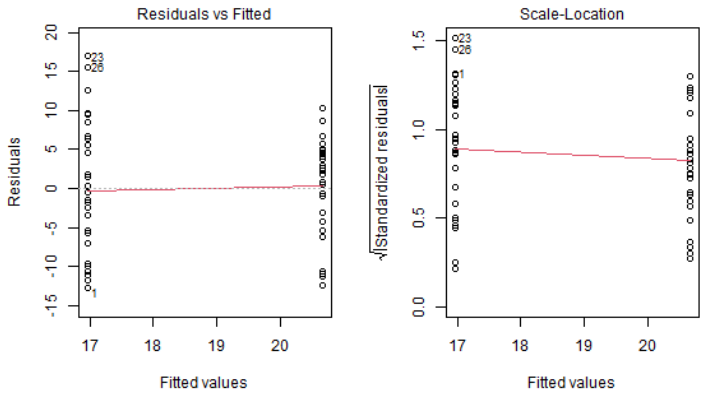

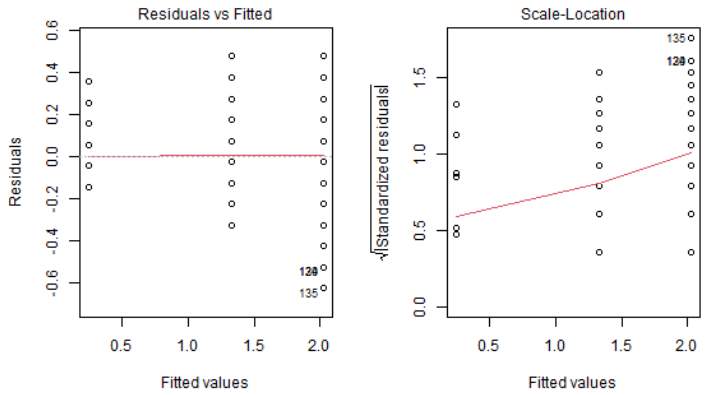

Probando heterocedasticidad

Prueba F para igualdad de varianzas (2 grupos)

Hipótesis

$$H_0 : \sigma_1^2 = \sigma_2^2 \qquad H_1 : \sigma_1^2 \neq \sigma_2^2$$

$$F = \frac{s_1^2}{s_2^2}$$

Dónde:

s_1^2 = varianza muestral del grupo 1

s_2^2 = varianza muestral del grupo 2

Probando heterocedasticidad

```r
var.test(len ~ supp, data = ToothGrowth)
```

```
##
##     F test to compare two variances
##
## data:  len by supp
## F = 0.6386, num df = 29, denom df = 29, p-value = 0.2331
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.3039488 1.3416857
## sample estimates:
## ratio of variances
##          0.6385951
```

Probando heterocedasticidad

Para más de dos niveles

- **Prueba de Breusch–Pagan**: Evalúa si la varianza de los residuos depende de los predictores.

$$H_0 : \mathrm{Var}(\varepsilon_i) = \sigma^2$$

$$BP = nR^2$$

Dónde:

n = tamaño de la muestra

R^2 = coeficiente de determinación de una regresión auxiliar (residuos cuadrados contra los predictores)

Probando heterocedasticidad

```r
lmtest::bptest(m2) #sobre un modelo
```

```
##
##     studentized Breusch-Pagan test
##
## data:  m2
## BP = 25.099, df = 2, p-value = 3.546e-06
```

Probando heterocedasticidad

- **Prueba de Levene**: Compara cuánto se dispersan los datos alrededor de su media en cada grupo.

Si las dispersiones son similares → homocedasticidad.

Hipótesis: $H_0 : \sigma^2 = \sigma_1^2 = \sigma_2^2 = \ldots = \sigma_k^2$

$$Z_{ij} = |Y_{ij} - \bar{Y}_{i\cdot}|$$

Z_{ij} = distancia absoluta del dato respecto a la media de su grupo

$$F = \frac{MS_{\text{entre grupos}}}{MS_{\text{dentro de grupos}}}$$

Probando heterocedasticidad

```r
library(car)
leveneTest(m2)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value    Pr(>F)
## group   2  19.892 2.261e-08 ***
##       147
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
?fligner.test
```

Análisis de varianza de una vía

- El **ANOVA de una vía** es el tipo de análisis que se emplea cuando los datos no están pareados y se quiere estudiar si existen diferencias significativas entre las medias de una variable aleatoria continua en los diferentes niveles de otra variable cualitativa o factor.

- Las hipótesis contrastadas en un ANOVA de un factor son:
  - H_0 : No existen diferencias entre las medias de los grupos, es decir $\mu_1 = \mu_2 = \ldots . \mu_k$
  - H_1 : Al menos un par de medias es significativamente diferente una de la otra

Análisis de varianza de una vía

- El ANOVA de una vía, crea una comparación entre la varianza en los datos que provienen de las diferencias entre grupos y la varianza en los datos que provienen de las diferencias dentro de los grupos.
  - $H_0 : \sigma^2_{entre} = 0 \rightarrow \sigma^2_{entre} + \sigma^2_{dentro} = \sigma^2_{dentro}$
  - $H_1 : \sigma^2_{entre} > 0 \rightarrow \sigma^2_{entre} + \sigma^2_{dentro} > \sigma^2_{dentro}$

Análisis de varianza de una vía

La forma en que el ANOVA hace esta comparación es evaluando las razones de las varianzas entre grupos y las varianzas dentro de los grupos:

- a nivel de población, si la razón es igual a 1, entonces las dos cosas son iguales
- si la razón es mayor que uno, entonces la varianza entre grupos es al menos un poco mayor que 0 y esto lo conocemos como el **el estadístico F**.

Análisis de varianza de una vía

El estadístico F se calcula así:

$$F = \frac{\sigma^2_{entre}}{\sigma^2_{dentro}} = \frac{intervarianza}{intravarianza} = \frac{\frac{n\Sigma(\bar{x}_k - \bar{x})^2}{k-1}}{\frac{\Sigma(x_k - \bar{x}_k)^2}{N-k}} = \frac{\frac{SCT}{k-1}}{\frac{SCE}{gl}}$$

siendo k los niveles, $N - k$ y $k - 1$ los grados de libertad y SC la suma de cuadrados del error (intravarianza) y de los tratamientos (intervarianza).

Análisis de varianza de una vía Tabla

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadros promedios	F
Entre Grupos	SCT	k-1	CMT = SCT/k-1	F=CMT/CME
Dentro de los grupos o Error	SCE	N-k	CME = SCE/N-k	
Total	STT	N-1		

Ejemplo aplicado

```
datos<- data.frame(Tratamiento1=c(-3.10,0.18,-0.72,0.09,-1.66),
                   Tratamiento2=c(7.28,3.06,4.74,5.29,7.88),
                   Tratamiento3=c(0.12,5.51,5.72,5.93,6.56),
                   Tratamiento4=c(8.18,9.05,11.21,7.31,8.83))
```

Tratamiento1	Tratamiento2	Tratamiento3	Tratamiento4
-3.10	7.28	0.12	8.18
0.18	3.06	5.51	9.05
-0.72	4.74	5.72	11.21
0.09	5.29	5.93	7.31
-1.66	7.88	6.56	8.83

Probemos los supuestos

Normalidad

```
ro1<- datos$Tratamiento1-mean(as.
ro2<- datos$Tratamiento2-mean(as.
ro3<- datos$Tratamiento3-mean(as.
ro4<- datos$Tratamiento4-mean(as.


shapiro.test(c(ro1,ro2, ro3, ro4)
```

```
##
##     Shapiro-Wilk normality test
##
## data:  c(ro1, ro2, ro3, ro4)
## W = 0.93347, p-value = 0.1801
```

Homocedasticidad

```
library(tidyverse)
datost<- datos %>% pivot_longer(c

lmtest::bptest(lm(Valor~Tratamien
```

```
##
##     studentized Breusch-Pagan test
##
## data:  lm(Valor ~ Tratamiento, data =
## BP = 2.3472, df = 3, p-value = 0.5035
```

Calculemos los grados de libertad

- Hay cuatro niveles entonces $k - 1$ = 3
- Hay cinco observaciones en cada grupo entonces $N - k$ = (4*5)-3 = 16
- Los grados de libertad totales son $N - 1$ = 20-1 = 19

Calculemos SCT

SCT = $n\Sigma(\bar{x}_k - \bar{x})^2$

```
SCT1= 5*(mean(datos$Tratamiento1)-mean(as.matrix(datos)))^2
SCT2= 5*(mean(datos$Tratamiento2)-mean(as.matrix(datos)))^2
SCT3= 5*(mean(datos$Tratamiento3)-mean(as.matrix(datos)))^2
SCT4= 5*(mean(datos$Tratamiento4)-mean(as.matrix(datos)))^2

SCT= (SCT1+SCT2+SCT3+SCT4); SCT
```

```
## [1] 257.9391
```

Calculemos SCE

SCE = $\Sigma(x_k - \bar{x_k})^2$

```
SCE1= sum((datos$Tratamiento1-mea
SCE2= sum((datos$Tratamiento2-mea
SCE3= sum((datos$Tratamiento3-mea
SCE4= sum((datos$Tratamiento4-mea

SCE = (SCE1+SCE2+SCE3+SCE4); SCE
```

```
## [1] 58.82228
```

Calculemos STT

STT = $\Sigma(x_k - \bar{x})^2$

```
STT1= sum((datos$Tratamiento1-mea
STT2= sum((datos$Tratamiento2-mea
STT3= sum((datos$Tratamiento3-mea
STT4= sum((datos$Tratamiento4-mea

STT = (STT1+STT2+STT3+STT4); STT
```

```
## [1] 316.7614
```

Calculemos CMT

```
CMT=SCT/(4-1);CMT
```

```
## [1] 85.97971
```

Calculemos F

```
valor_F= CMT/CME; valor_F
```

```
## [1] 23.38698
```

Calculemos CME

```
CME=SCE/(20-4);CME
```

```
## [1] 3.676393
```

Calculemos el valor p

```
valor_p<-pf(valor_F, df1=4-1, df2
```

```
## [1] 4.313444e-06
```

Hagámoslo en R

```
anova_R<- aov(Valor~Tratamiento, data = datost)
summary(anova_R)
```

```
##             Df Sum Sq Mean Sq F value   Pr(>F)
## Tratamiento  3 257.94   85.98   23.39 4.31e-06 ***
## Residuals   16  58.82    3.68
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Comparando...

```
valor_F;valor_p
```

```
## [1] 23.38698
```

```
## [1] 4.313444e-06
```

Referencias y material suplementario

- Advanced Statistics I 2021 Edition
- Pruebas paramétricas y no paramétricas
- Estadística paramétrica y no paramétrica
- Prácticos de bioestadística 2